Visualisation de données

De la donnée massive au tableau de bord décisionnel

Projet : du data lake au dashbord

Mastère Big Data & IA — M1 · Session 2026-2027 · **Enseignant** : M. L. NDAO

Le principe

Vous choisissez un jeu de données, un décideur qui en a besoin (le persona), et vous construisez pour lui un tableau de bord. Entre les deux, vous refaites toute la chaîne vue en cours : stockage, préparation, sémantique, visualisation.

En binôme. Rendu sur un **dépôt GitHub dédié**.

1. Le jeu de données

— Au moins **2 millions de lignes**, avec une dimension temporelle et, si possible, une dimension géographique.

— Des données ouvertes, téléchargeables par un script.

— Pas de NYC Taxi : c'est le jeu de données du cours.

Quelques pistes

Vélib' et comptages routiers (Paris Open Data), transactions immobilières DVF, vols et retards aux États-Unis (BTS), consommation électrique (RTE, Enedis), qualité de l'air, accidents de la route, data.gouv.fr, Kaggle.

2. Le persona

Décrivez votre décideur : qui il est, ce qu'il décide, à quelle fréquence, et surtout **la question principale** à laquelle votre tableau de bord doit répondre.

3. Le stockage : *bronze*, *silver*, *gold*

— ***Bronze*** : les données brutes, en Delta dans RustFS, sans transformation.

— ***Silver*** : nettoyage et typage. Listez chaque règle de nettoyage et le nombre de lignes qu'elle retire.

— ***Gold*** : des agrégats construits pour répondre à la question du persona, exportés dans PostgreSQL.

4. La sémantique

— Une petite ontologie (`.ttl`) qui décrit les concepts de votre domaine et leurs relations.

— Au moins **trois requêtes SPARQL** qui répondent à des questions utiles au persona.

5. La visualisation

— Un notebook d'exploration avec vos graphiques.

— Un **avant/après** : un graphique dans une première version naïve, puis sa version corrigée. Justifiez chaque correction par les principes de perception vus en cours.

6. Le tableau de bord Streamlit

— Trois à cinq KPI, chacun décrit dans une fiche : définition, calcul, intérêt pour le persona.

— Des graphiques organisés en récit : contexte, constat, recommandation.

— Au moins un filtre interactif.

— Un lancement par `docker compose`.

7. Le rendu

Créez un **nouveau dépôt GitHub**, distinct de votre fork du cours, nommé `projet-dataviz-<nom1>-<nom2>`. Il doit être public ou privé, avec mon compte ajouté en tant que collaborateur. Vous pouvez vous inspirer de la structure du repository du cours.

Les données ne sont pas versionnées. Je dois pouvoir cloner votre dépôt, lancer le script de téléchargement, puis `docker compose up -d`, exécuter les notebooks dans l'ordre, et obtenir votre tableau de bord.

Attention ! !

Toutes les modifications doivent être documentées via des commits des auteurs. La documentation de ces commits aura un poids sur la note.

8. Calendrier

Deux échéances

30/10/2026	Envoi du lien du dépôt, avec un `README.md` qui présente le jeu de données et le persona. Je valide ou je vous demande d'ajuster.
30/11/2026	Rendu final : seul le dernier *commit* avant cette date est pris en compte.